

Modelo logístico binomial para determinação da maciez de carne bovina de forma não destrutiva

Me. Yuri Ajala Da Costa^{1*}; Prof. Dr. Ricardo Janes²

¹ Universidade de São Paulo – Escola Superior de Agronomia Luiz de Queiroz
Av. Pádua Dias, 11 - Cx. Postal 9 – Piracicaba, SP, Brasil - CEP 13418-900

² FEI. Doutor em Engenharia Elétrica. Av. Humberto de Alencar Castelo Branco, 3972-B – Assunção; 09850-901,
São Bernardo do Campo, SP, Brasil

*autor correspondente: yuri.ajala@gmail.com

Modelo logístico binomial para determinação da maciez de carne bovina de forma não destrutiva

Resumo

O Brasil ocupa a posição de maior exportador de carne bovina do mundo e a classificação da maciez da carne é crucial para otimizar o controle de qualidade e maximizar os ganhos na indústria. A ressonância magnética nuclear [RMN] como técnica de controle de qualidade vem crescendo cada vez mais no mercado da indústria alimentícia, e pode ser uma ferramenta para classificar a maciez de amostras de carne sem destruí-las, diferentemente dos métodos padrão ouro atuais. O objetivo deste estudo é usar modelagem de regressão logística binomial na classificação de carnes como “dura” (classe = 0) ou “macia” (classe = 1) usando dados sintéticos. Foi criado um conjunto de dados simulando amostras de carne (n=1000), contendo como variáveis a intensidade de sinal de RMN, umidade e luminosidade. A obtenção dos valores foi feita a partir de números aleatórios de distribuições normais com média e desvio padrão compatíveis com as características reais das variáveis. As classes atribuídas a cada amostra foram escolhidas seguindo uma regra dependente da intensidade de sinal. A análise exploratória dos dados foi feita utilizando estatística descritiva e pair plots com dispersão entre variáveis e estimativas de densidade de kernel. Foi realizada a regressão do logito e calculadas as matrizes de confusão, sensibilidade, para valores de threshold de 0,3, 0,5 e 0,7, além da curva ROC e coeficiente de Gini. A área abaixo da curva foi de 0,973 e o coeficiente de Gini foi de 0,946. Por fim, foram discutidas as implicações comerciais e econômicas da escolha de um threshold adequado. A síntese dos dados e as análises foram realizadas em Python e disponibilizadas em repositório virtual de livre acesso.

Palavras-chave: regressão; dados sintéticos; RMN; logito

Introdução

A ressonância magnética nuclear [RMN], ou simplesmente ressonância magnética, é uma técnica não destrutiva de análise de amostras. Existem três principais tipos de equipamentos, cada um voltado para um tipo de análise: espectroscopia por RMN, utilizado para a determinação de composição de amostras (Gunther, 1995); imagem por RMN, utilizado na área médica para análise morfológica de órgãos humanos e animais (Azhar e Chong, 2023); e relaxometria por RMN, ou RMN-DT (ressonância magnética nuclear no domínio do tempo), utilizado na análise de amostras como grãos e óleos para determinar suas propriedades (Cobo et al., 2017), esta última sendo o tipo de análise que nos interessa aqui. A RMN-DT encontra sua aplicação principal no nicho de qualidade de alimentos, por se tratar de uma técnica mais segura, simples, limpa e rápida do que as técnicas por tratamento químico das amostras (Ozel e Oztop, 2021). É utilizada, dentre outras aplicações, para identificar umidade em óleos, ou a quantidades e tipos de óleos presentes em uma amostra de sementes.

O Brasil ocupa a posição de maior exportador de carne bovina do mundo (Ministério da Agricultura e Pecuária, 2024). Dentre as características sensoriais da carne, a maciez é considerada a de maior importância para o consumidor (Leidenz, 2000). A carne que passa pelo processo de maturação torna-se mais macia e com paladar diferenciado.

Existem diferentes formas de avaliar a maciez de um corte cárneo, e até recentemente todas elas requeriam a destruição da amostra, como na força de cisalhamento e painel sensorial (Destefanis et al. 2008).

No teste de força de cisalhamento, um bife de contrafilé de 2 cm de altura é descongelado, assado em forno, descansado, e dele obtém-se pequenas amostras em forma de cilindros de carne (de 4 a 8). Finalmente, faz-se uso de uma lâmina de Warner-Bratzler acoplada a um equipamento de texturômetro que mede a força aplicada na lâmina para cortar cada amostra de carne (Warner et al., 2021). Este processo todo leva 2 dias e requer a destruição da amostra. Valores acima de 4,37 kgf são considerados duros, e abaixo são macios (Destefanis et al., 2008). Assim, infere-se então o grau de maciez de um grupo de animais que tem as mesmas características (raça, peso, idade, sexo, alimentação, etc). Por outro lado, o painel sensorial é uma medida subjetiva em que os participantes experimentam diferentes amostras da carne assada e pontuam suas qualidades, incluindo maciez (Warner et al., 2021).

Como a RMN-DT tem se mostrado uma ferramenta eficaz no que diz respeito à quantificação de umidade e gorduras nas mais diferentes amostras, e considerando que a literatura mostra que a presença de água e gordura na carne são fatores importantes para determinar sua maciez, hipotetizou-se ser possível usar a tecnologia para estimar a maciez

de um corte cárneo de forma não destrutiva, juntamente com análise de umidade e de luminosidade da amostra.

Propõe-se um modelo de regressão logístico binomial que inclui a intensidade de sinal de RMN, a umidade e a luminosidade, com objetivo de identificar a classe pertencente da amostra, seja ela dura (classe=0) ou macia (classe=1). O modelo será avaliado com o procedimento stepwise para reduzi-lo às variáveis significativas e serão calculadas as métricas associadas à qualidade do modelo: matriz de confusão para diferentes thresholds, curva ROC e coeficiente de GINI. Serão discutidas ainda as implicações comerciais e econômicas da escolha de diferentes thresholds.

Este trabalho baseia-se na experiência similar de pesquisa e desenvolvimento em uma empresa nacional de equipamentos de RMN-DT para a área alimentícia situada em São Carlos - SP, com laboratórios de testes em São José do Rio Preto, realizada entre os anos de 2019 e 2021. Os testes originais foram conduzidos com supervisão de uma zootecnista e um físico responsáveis, parte do quadro de funcionários da empresa.

Objetivo

Classificar sinais sintéticos de RMN-DT, umidade e luminosidade como pertencentes à carne bovina dura ou macia.

Materiais e Métodos

A análise por RMN-DT de uma amostra resulta em uma curva exponencial decrescente com características como amplitude (intensidade de sinal) e constante de decaimento determinadas pela amostra, como ilustrado na Figura 1. Pode-se ainda acrescentar outras características como umidade, características de cor, e pH. Neste trabalho, as variáveis independentes consideradas são: amplitude do sinal de RMN-DT, umidade em % e luminosidade L^* .

Síntese das variáveis e observações

Foram criadas três variáveis sintéticas: intensidade de sinal, umidade, e luminosidade, representando os testes laboratoriais comumente executados.

Para a variável intensidade de sinal, foram sorteados números ($n = 1000$) de uma distribuição normal com média 30 unidades arbitrárias (u.a.) e desvio padrão 15 u.a.. Em caso de sorteio de número negativo, a variável toma valor zero para aquela observação. Para cada número de intensidade de sinal sorteado foi atribuída a classe correspondente. Se a intensidade de sinal for igual ou menor que 35 u.a., a classificação recebe valor zero, por ser um não-evento (carne dura). Se a intensidade de sinal for entre 35 e 45 u.a., será atribuído um valor aleatório 0 ou 1 (carne dura ou macia) para reproduzir a zona de transição. Se a intensidade de sinal for maior ou igual a 45 u.a., a classe assume valor 1 (carne macia).

A variável umidade foi criada com o sorteio de números aleatórios de uma distribuição normal com média 60% e desvio padrão de 20%. Os valores da variável luminosidade foram obtidos também com números aleatórios seguindo uma distribuição normal, mas com média 70 (adimensional) e desvio padrão 5. Por fim, foi criado um dataframe com 1000 observações e as variáveis: classe, intensidade de sinal, umidade e luminosidade. Os sorteios foram realizados utilizando a biblioteca numpy do Python e o dataframe com a biblioteca pandas. A base de dados foi salva em arquivo do tipo comma separated value (csv) para ser disponibilizada para fins didáticos.

A análise exploratória dos dados foi realizada com base na estatística descritiva do dataset e a criação do conjunto de gráficos “pair plot” com dispersão e estimativas de densidade de kernel [KDE] para avaliar a separabilidade das classes e identificar zonas de sobreposição. A regressão do logito foi realizada usando a biblioteca statsmodels com algoritmo de estimação de máxima verossimilhança (MLE) e o procedimento stepwise com a biblioteca statstests. A matriz de confusão, sensibilidade, especificidade e acurácia foram calculadas para os thresholds 0,3, 0,5, e 0,7. Será ainda calculada a curva ROC, a área abaixo da curva [AUC] e o coeficiente de Gini.

A síntese dos sinais, procedimento stepwise e a métricas de qualidade foram disponibilizadas em Jupyter Notebooks no GitHub (<https://github.com/yuriajala/mba-usp-esalq-tcc-dsa232>). Na figura 1 é possível visualizar as curvas referentes aos sinais de RMN de carne dura (vermelha) e macia (azul).




Figura 1 – Curvas referentes aos sinais de RMN de carne dura (vermelha) e macia (azul)

Fonte: Dados originais da pesquisa.

Resultados

Análise exploratória

Uma vez criado o dataset composto de 1000 observações, inicia-se a análise exploratória desses dados. A Tabela 1 traz a estatística descritiva do banco de dados. Observa-se que as médias e desvios padrão das variáveis (exceto classe) se aproximaram

dos valores estabelecidos em sua criação: médias 30, 0.6 e 70, e desvios padrão 15, 0.2, e 5, para intensidade de sinal, umidade e luminosidade, respectivamente.

Tabela 1 – Estatística descritiva do banco de dados

	Classe	Intensidade de sinal	Umidade	Luminosidade
Número de observações	1000.000000	1000.000000	1000.000000	1000.000000
Média	0.258000	29.850511	0.603392	69.882533
Desvio Padrão	0.437753	14.211364	0.200798	5.020484
Mínimo	0.000000	0.000000	0.000000	51.003242
Máximo	1.000000	74.951726	1.411920	85.245256

Fonte: Resultados originais da pesquisa.

Os gráficos pairplot mostrados na Figura 2 mostra as estimativas de densidade de kernel na diagonal principal, e o gráfico de dispersão para as três variáveis de entrada. As cores das observações estão codificadas de acordo com a classe. A estimativa de densidade de kernel da variável intensidade de sinal apresenta separação parcial de classes, enquanto as variáveis umidade e luminosidade têm as duas classes sobrepostas. O gráfico de dispersão de umidade *versus* luminosidade evidencia essa sobreposição e consequente inseparabilidade de classes. Os outros gráficos de dispersão, de umidade ou luminosidade contra intensidade de sinal mostram que a separabilidade das classes é dependente da intensidade de sinal, o que é esperado considerando a forma que os dados foram sintetizados.




Figura 2: Pair plot das variáveis independentes

Fonte: Resultados originais da pesquisa

Ajuste do modelo

O ajuste do modelo alcançou um pseudo R^2 de 0,675, indicando que os preditores (intensidade de sinal, umidade e luminosidade) explicam grande parte da variabilidade da variável classe. O log-likelihood [LL] do modelo (intercepto e variáveis preditoras) foi de -185,44, enquanto que o LL do modelo nulo (somente intercepto) foi de -570,95. O p-valor do log-likelihood ratio [LLR] foi menor que 0,001, praticamente zero, indicando que pelo menos uma variável preditora contribui significativamente para o modelo, quando comparado com o modelo nulo.

A Tabela 2 traz os resultados da regressão do logito incluindo as três variáveis preditoras. O intercepto tem coeficiente -16,737 com $p < 0,001$, indicando que quando todos os preditores são zero, o logaritmo da razão de chances (log-odds) de classificar uma amostra como macia (classe = 1) é virtualmente zero e variáveis são necessárias para aumentar o log-odds. A intensidade de sinal recebeu o coeficiente 0,355 com $p < 0,001$, indicando que maiores valores aumentam significativamente a probabilidade de uma amostra ser classificada como “macia”. Como esperado, umidade e luminosidade não contribuíram significativamente para o modelo, ambos com coeficientes com p-valor maior que 0,05.

Tabela 2 – Resultados da regressão do logito considerando as três variáveis independentes

	Coeficiente	Erro padrão	Z	p > z	[0.025	0.975]
Intercepto	-16.7372	2.258	-7.412	0.000	-21.163	-12.311
intensidade_sinal	0.3558	0.027	13.045	0.000	0.302	0.409
umidade	-0.0312	0.640	-0.049	0.961	-1.286	1.224
luminosidade	0.0369	0.026	1.419	0.156	-0.014	0.088

Fonte: Resultados originais da pesquisa.

O procedimento stepwise remove iterativamente variáveis preditoras baseado na significância estatística, buscando identificar a melhor combinação de variáveis que contribui para o desempenho do modelo. Neste caso, ele descartou as variáveis umidade e luminosidade e deixou o modelo dependente apenas da variável intensidade de sinal. A Tabela 3 traz os resultados da regressão considerando o procedimento stepwise.

Tabela 3 – Resultados da regressão após o procedimento stepwise

	Coeficiente	Erro padrão	Z	p > z	[0.025	0.975]
Intercepto	-14.049	1.051	-13.371	0.000	-16.109	-11.990
intensidade_sinal	0.3525	0.027	13.130	0.000	0.300	0.405

Fonte: Resultados originais da pesquisa.

A Figura 3 mostra a sigmoide probabilística ajustada à dispersão das observações, demonstrando claramente a relação entre intensidade de sinal e a probabilidade de ser classificada como “macia”. À medida que a intensidade de sinal aumenta, a probabilidade sai de próxima de zero (indicando amostras duras) até próxima de um (indicando amostras macias). Os pontos verdes se mostram aglomerados nos valores mais baixos de intensidade de sinal, assim como os rosas estão aglomerados nos valores mais altos de intensidade de sinal, com uma zona de interseção centrada no ponto de inflexão da sigmoide, próximo de 40 u.a., o que é condizente com a regra de criação dos dados que registrava uma classe aleatória para os valores de intensidade de sinal entre 35 e 45 u.a..

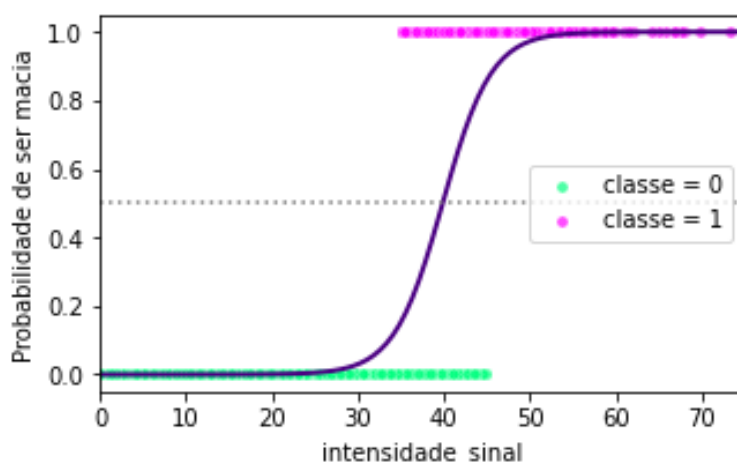


Figura 3: Ajuste logístico probabilístico da intensidade de sinal e a probabilidade de a amostra ser da classe “macia” (valor 1).

Fonte: Resultados originais da pesquisa

Avaliação do modelo

As Tabelas 4, 5 e 6 são as matrizes de confusão para os thresholds de 0,3, 0,5 e 0,7, respectivamente. A Tabela 7 traz os valores de sensibilidade, especificidade e acurácia para os mesmos thresholds.

Tabela 4 – Matriz de confusão para threshold 0,3

Threshold = 0.3	Verdadeiro “macia”	Verdadeiro “dura”
Classificado “macia”	225	69
Classificado “dura”	33	673

Fonte: Resultados originais da pesquisa.

Tabela 5 – Matriz de confusão para threshold 0,5

Threshold = 0.5	Verdadeiro “macia”	Verdadeiro “dura”
Classificado “macia”	198	48
Classificado “dura”	60	694

Fonte: Resultados originais da pesquisa.

Tabela 6 – Matriz de confusão para threshold 0,7

Threshold = 0.7	Verdadeiro “macia”	Verdadeiro “dura”
Classificado “macia”	183	20
Classificado “dura”	75	722

Fonte: Resultados originais da pesquisa.

Tabela 7 – Valores de sensibilidade, especificidade e acurácia para cada threshold

	Sensibilidade	Especificidade	Acurácia
Threshold 0.3	0.872	0.907	0.898
Threshold 0.5	0.767	0.935	0.892
Threshold 0.7	0.709	0.973	0.905

Fonte: Resultados originais da pesquisa.

Curva ROC e métricas associadas

A curva ROC, mostrada na Figura 4, confirma visualmente a habilidade do modelo em distinguir entre amostras duras e macias a diferentes thresholds. Quanto mais próxima a curva se encontra do canto superior esquerdo, maior a área abaixo da curva (AUC) e o coeficiente de Gini. A AUC assumiu o valor de 0,9732, indicando que em 97,32% das vezes o modelo consegue ranquear uma amostra macia aleatória acima de uma amostra dura aleatória no ranking de probabilidades de ser macia (evento). O coeficiente de Gini, de 0,9465 quantifica a habilidade do modelo de separar as classes. Um coeficiente próximo de 1 reforça a conclusão de que o modelo tem um grande poder de classificação.

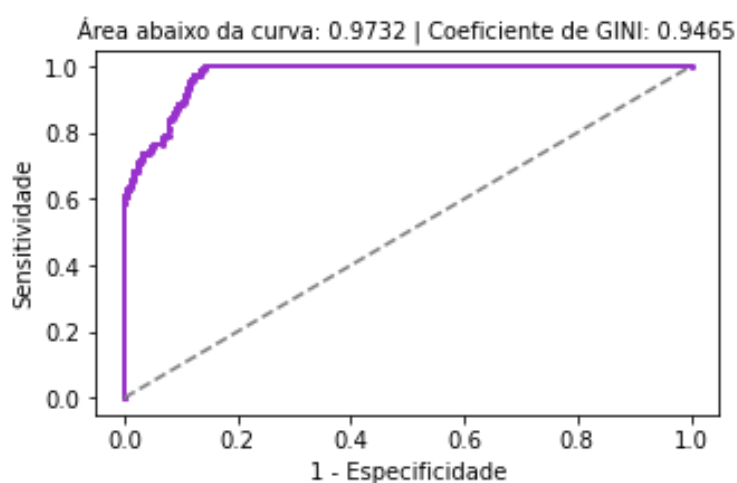


Figura 4: Curva ROC do modelo de regressão logístico

Fonte: Resultados originais da pesquisa.

Implicações da escolha do threshold no modelo de negócios

Os erros de falso positivo, também chamados de erro de tipo I, quando uma amostra “dura” é classificada como “macia”, são particularmente problemáticos, pois a venda de uma peça de carne dura com preço e etiqueta de macia resulta na quebra de expectativa do consumidor que esperava uma qualidade premium, além da perda de credibilidade da empresa e danos à sua imagem. Por outro lado, os erros do tipo II, de falso negativo, quando

uma amostra “macia” é classificada como “dura”, significam perder a oportunidade de vender um produto com preço de premium por ter sido classificado erroneamente como um padrão de produto tradicional.

Dado este cenário, pode-se optar por um valor de threshold como 0,7, que tem alta especificidade, no qual a maioria dos cortes cárneos duros são assim classificados (apenas 2,7% são classificados erroneamente), garantindo a boa imagem da marca ao custo de perda de sensibilidade (70,9%), onde 29,1% de cortes macios serem classificados como duros e consequente perda de receita. Um threshold de 0,3, por outro lado, tem alta sensibilidade (87,2%), indicando que a maioria das peças macias são assim classificadas, mas perde especificidade, de forma que 9,3% das peças duras seriam classificadas como macias, comprometendo a imagem da empresa. O threshold de 0,5 traz um compromisso entre sensibilidade e especificidade, onde 76,7% dos cortes macios seriam corretamente identificados, e 93,5% dos cortes duros serem corretamente identificados.

Considerando o contexto onde manter uma marca forte é imperativo e os cortes macios erroneamente classificados como duros façam parte da estratégia do modelo de negócios, faz sentido escolher um threshold que maximize a especificidade, ainda que signifique perder sensibilidade, como o de valor 0,7.

Conclusão

O modelo logístico de regressão calculado se mostrou efetivo na classificação binária das amostras sintetizadas, com alto grau de acurácia, como evidenciado pela AUC de 0,973 e coeficiente de Gini de 0,946. Dentre os três preditores iniciais, a intensidade de sinal foi o único que se mostrou estatisticamente significativo para formar o logito junto com o intercepto. Através da escolha do threshold, a empresa pode balancear rentabilidade e controle de qualidade, oferecendo um produto premium confiável.

Referências

Azhar S.; Chong L. R. 2023. Clinician's guide to the basic principles of MRI. *Postgraduate Medical Journal* 99(1174): 894-903

Cobo M. F.; Deublein, E. J.; Haber A.; Kwamen R.; Nimbalkar M.; Decker F. 2017. TD-NMR in quality control: standard applications. Em: *Modern magnetic resonance*. Springer, Cham, Switzerland.

Destefanis, G.; Brugiapaglia, A.; Barge, M. T; Molin, E. D. 2008. Relationship between beef consumer tenderness perception and Warner-Bratzler shear force. *Meat Science*. v.78. 153-156.

Gunther, H. 1995. *NMR spectroscopy*. 2ed. John Wiley and Sons, New York, USA.

Leidenz, N.H. 2000. Parâmetros de qualidade de carne para o início do milênio. *Congresso brasileiro das raças zebuínas (anais)* 243-259.

Ministério da Agricultura e Pecuária, 2024. Carne bovina e milho são destaques na exportação brasileira. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/noticias/carne-bovina-e-milho-sao-destaques-na-exportacao-brasileira>>. Acesso em: 04/11/2024.

Ozel B.; Oztop M. H. 2021. A quick look to the use of time domain nuclear magnetic resonance relaxometry and magnetic resonance imaging for food quality applications. *Current opinion in food science*. v.41. 122-129

Pardi, M.C.; Santos, I.F.; Souza, E.R. 1995. Em: *Ciência, higiene e tecnologia da carne*. Editora da UFG, Goiânia, Brasil

Pereira, F. M. V.; Pflanzner Junior, S. B.; Gomig, T.; Gomes, C. L.; Felício, P. E.; Colnago, L. A. 2013. Fast determination of beef quality parameters with time-domain nuclear magnetic resonance spectroscopy and chemometrics. *Talanta*. v108. 88–91.

Warner, R.; Miller, R.; Ha, M.; Wheeler, T. L.; Dunshea, F.; Li, X.; Vaskoska, R.; Purslow, P. 2021. Meat Tenderness: Underlying Mechanisms, Instrumental Measurement, and Sensory Assessment. *Meat and Muscle Biology*. 4(2) 17. 1–25.